DECUBO: Diminuta Evaluación Cultural Bonaerense

Benchmark de entendimiento contextual bonaerense en LLMs mediante un corpus literario regional

Lautaro D. Barceló, Tadeo Donegana Braunschweig, Tadeo Wassner Penko

16 de noviembre de 2024

Palabras clave: Benchmarking de LLMs, Comprensión de lectura, Textos literarios, Variedades lingüísticas, Dialectos regionales, Cultura argentina, Provincia de Buenos Aires, NLP, Procesamiento del lenguaje natural

Resumen

Los modelos de lenguaje de gran escala (LLMs) han demostrado capacidades excepcionales en tareas de procesamiento de texto, pero su rendimiento varía significativamente según el contexto cultural y lingüístico. Este trabajo presenta DECUBO (Diminuta Evaluación Cultural Bonaerense), un benchmark diseñado para evaluar la comprensión de textos literarios situados en la Provincia de Buenos Aires, Argentina. Trabajando con la Dirección Provincial de Bibliotecas y Promoción de la Lectura, seleccionamos un corpus de 21 textos literarios diversos y desarrollamos 68 preguntas de opción múltiple que evalúan la comprensión de referencias culturales, geográficas y lingüísticas específicas de la región. Evaluamos cinco modelos de lenguaje prominentes (GPT-4, Claude 2.1, Llama 3 70B, Llama 3 8B y Mistral 7B) en este benchmark. Los resultados muestran un rendimiento superior de GPT-4 (93.10 %) y Llama 3 70B (91.18 %), mientras que los modelos más pequeños obtuvieron resultados significativamente menores. El análisis de errores revela dificultades consistentes en la comprensión de referencias geográficas específicas y contextos culturales locales, sugiriendo limitaciones persistentes en la capacidad de los LLMs para procesar textos situados.

1. Introducción

Los LLMs (Large Language Models) se han convertido en un componente fundamental de los sistemas informáticos modernos, al demostrar capacidades sin precedentes en múltiples tareas y dominios que requieran procesamiento o generación de texto. En los últimos años, estos modelos han alcanzado y superado el rendimiento humano en diversos puntos de referencia establecidos por la comunidad científica: desde evaluaciones lingüísticas básicas hasta tareas complejas de razonamiento. [1].

2. Justificación

A medida que estos modelos se despliegan globalmente, emerge una preocupación fundamental: la dominancia lingüística y los sesgos culturales inherentes en su funcionamiento. Estudios recientes han demostrado que los LLMs exhiben un rendimiento significativamente superior en inglés en comparación con otros idiomas [2], reflejando disparidades en la cantidad y calidad de los datos de entrenamiento disponibles para diferentes lenguas.

Una medida precisa del rendimiento de los LLMs en diferentes contextos lingüísticos y culturales se vuelve particularmente importante cuando estos sistemas se implementan en entornos donde el inglés no es la lengua predominante. Los métodos tradicionales de evaluación, desarrollados principalmente en y para el idioma inglés, pueden no capturar adecuadamente las sutilezas y particularidades de otros contextos lingüísticos y culturales. La evaluación de LLM se ha concentrado tradicionalmente en benchmarks estandarizados que, en su mayoría, reflejan perspectivas y contextos anglocéntricos. Esta limitación se vuelve particularmente evidente al evaluar el desempeño de los LLMs en entornos geográficos y culturales específicos. Además, la mayoría de los benchmarks para LLM son simplemente traducidos usando una herramienta automatizada y luego ejecutados en el idioma objetivo [3].

En el contexto específico de la provincia de Buenos Aires, la más poblada de Argentina, la necesidad de herramientas de evaluación adaptadas culturalmente se vuelve evidente: los LLMs ya son una herramienta clave en aulas y oficinas, siendo Argentina uno de los países en los que más se popularizaron herramientas como ChatGPT [4]. La rica tradición literaria y cultural de la región, con sus particulares expresiones lingüísticas y referencias culturales, representa un desafío para los LLMs. Estas particularidades no solo incluyen variaciones dialectales del español, sino también referencias históricas, culturales y sociales específicas que forman parte integral del discurso cotidiano y académico en la región.

3. Marco Teórico

3.1. Dominancia lingüistica

De acuerdo a los datos proporcionados por OpenAI[5], modelos como GPT-4 que fueron testeados con el benchmark MMLU[6] mostraron una exactitud mucho menor en idiomas como el Thai (71,8 %), el Telugu (62,0 %) que en el inglés (85,5 %) o el español (84,0 %). Este fenómeno de dominancia lingüística se manifiesta de dos maneras distintas. Por un lado, en tareas agnósticas al lenguaje (language-agnostic), como el razonamiento matemático o el conocimiento científico general, los modelos tienden a mostrar un mejor desempeño cuando operan en inglés, independientemente del contexto cultural [7]. Por otro lado, en tareas específicas del lenguaje (language-specific) que requieren comprensión de contextos sociales, culturales o geográficos particulares. Según Zhao et al, el rendimiento óptimo se alcanza cuando se utiliza el idioma nativo del contexto en cuestión.

3.2. Sentido común geográficamente situado

El sentido común, a diferencia del conocimiento factual, se adquiere a través del tiempo mediante la exploración y el aprendizaje cultural [8]. Esto implica normas societales compartidas y expectativas que pueden variar significativamente según el contexto geográfico. Por ejemplo, mientras que "los vestidos de novia son típicamente rojos" es una norma cultural compartida en China, India y Vietnam, no lo es en Italia o Francia. De manera similar, "traer un regalo cuando visitás a alguien" es una creencia sostenida en Rumania, Japón y Rusia, pero no necesariamente en los Estados Unidos o Finlandia.

3.3. Impacto en la comprensión textual

Esta variabilidad geográfica del sentido común presenta desafíos particulares para la evaluación de LLMs en contextos específicos. Investigaciones recientes han demostrado que los modelos exhiben un rendimiento significativamente dispar cuando se evalúan en diferentes contextos culturales, con una tendencia a favorecer el conocimiento del sentido común asociado con culturas dominantes en sus datos de entrenamiento [Shen et al., 2024]. En el contexto bonaerense, esto se manifiesta en la interpretación de referencias culturales que, aunque evidentes para los habitantes locales, pueden resultar opacas o ser malinterpretadas por sistemas entrenados principalmente con datos de otras regiones.

3.4. La provincia de Buenos Aires

Así como se señala que "numerosos aspectos de la vida humana —como la cultura, raza, lenguaje, economía, política y religión— se proyectan significativamente en el espacio geográfico" [9], los 307.571 km cuadrados de la provincia de Buenos Aires delimitan un espacio geográfico colmado de textos. Dentro del espacio rioplatense y, más ampliamente, de la nación Argentina. La literatura argentina, y en este caso específicamente bonaerense, tiene sus propias "geografías literarias"[10] lugares que son construcciones narrativas además de espacios físicos, como la Mar del Plata de Bioy o la Villa Gesell de Juan Forn.

3.5. El texto literario

La literatura es un discurso altamente codificado que condensa una gran cantidad de información: mientras más códigos maneje el lector, más información obtendrá del texto [11]. Los textos considerados literarios tienen o suelen presentar usos marcados o desviados del lenguaje estándar. La literatura frecuentemente rompe reglas gramaticales y convenciones lingüísticas de manera intencional. La polisemia, o multiplicidad de significados, es una característica inherente del lenguaje que se intensifica especialmente en los textos literarios. Esta propiedad permite que una misma palabra, frase o pasaje pueda interpretarse de diferentes maneras según el contexto en que se analice. Esta riqueza semántica resulta particularmente valiosa para la construcción de datasets de opción múltiple, ya que:

- Permite generar distractores plausibles basados en interpretaciones alternativas pero válidas del texto
- Facilita la creación de opciones que juegan con diferentes niveles de comprensión (literal, inferencial, crítico, etc)
- Posibilita formular respuestas que, aunque incorrectas para la pregunta específica, mantienen una relación lógica con el texto

3.6. LLMs

3.6.1. Modelos utilizados

Claude 2.1 (2023) Desarrollado por Anthropic y lanzado a mediados de 2023, se distingue por su capacidad de procesamiento de texto de alta calidad y su enfoque en alineación con valores éticos. Su arquitectura permite el análisis de documentos extensos y mantiene una coherencia notable en conversaciones largas, destacándose especialmente en tareas de razonamiento complejo y análisis crítico. Una característica distintiva es su capacidad para proporcionar explicaciones detalladas y matizadas.

Mistral 7b (2023) Lanzado por Mistral AI en septiembre de 2023, representa un avance significativo en modelos de lenguaje de tamaño medio. A pesar de su relativa compacidad (7 mil millones de parámetros), demuestra capacidades sorprendentemente robustas en múltiples tareas de procesamiento de lenguaje natural. Su eficiencia computacional y rendimiento competitivo lo han convertido en una opción atractiva para implementaciones prácticas y experimentación académica.

Llama 3 8b (2024) Desarrollado por Meta AI como parte de su tercera generación de modelos Llama lanzada a principios de 2024, esta versión compacta demuestra una notable eficiencia en relación a su tamaño. Con solo 8 mil millones de parámetros, ofrece un rendimiento sorprendentemente robusto en tareas generales de procesamiento de lenguaje, manteniendo un equilibrio entre eficiencia computacional y capacidad de respuesta.

Llama 3 70b (2024) La versión más potente de la familia Llama 3, lanzada junto con el resto de la serie en 2024, con 70 mil millones de parámetros, representa un salto significativo en capacidades. Este modelo exhibe una comprensión más profunda del contexto y mejoras sustanciales en tareas complejas de razonamiento. Su arquitectura refinada y mayor escala le permiten abordar tareas más sofisticadas mientras mantiene la filosofía de código abierto característica de Meta AI.

GPT-4 (2023) Desarrollado por OpenAI y lanzado en marzo de 2023, representa el estado del arte en modelos de lenguaje de gran escala. Se destaca por su capacidad multimodal, pudiendo procesar tanto texto como imágenes, y demuestra un nivel excepcional de comprensión y generación de contenido. Sus capacidades de razonamiento avanzado y adaptabilidad a diversos contextos lo han posicionado como referente en aplicaciones profesionales y de investigación. La arquitectura del modelo y sus detalles técnicos específicos permanecen en gran medida confidenciales, siguiendo la política de OpenAI.

3.6.2. Costos asociados

La implementación de este trabajo requiere el uso de LLMs, específicamente a través de Amazon Bedrock, una plataforma de servicios administrados que facilita el acceso a diversos modelos fundacionales. El acceso a estos modelos se realizó mediante APIs, lo cual implica costos operativos basados en el uso. La estructura de costos se determina principalmente por el volumen de tokens procesados, tanto en las solicitudes (prompts)

Título	Autor	Género
“El mar, modo de uso” (en Los Viernes)	Juan Forn	Ensayo
“Polemistas” (en Cuentos breves y extraordinarios)	Borges & Bioy	Aguafuerte
“El pueblo de Patagones” / “La tragedia de un padre que va a Mar del Plata”	Roberto Arlt	Crónica
“Qué romántico” (en La canción del amor)	Celeste Dieguez	Poesía
“El baquiano y el rastreador” (en Radiografía de la pampa)	Ezequiel Martínez Estrada	Ensayo
“Réquiem para Marcial Palma” (en Cuentos Crueles)	Abelardo Castillo	Cuento
“Nomeolvides”	Roberta Iannamico	Poesía
“Llevo la tos como propia voz” (en Sobre el rock)	Martín Zariello	Crítica
“Tristezas del vino de la costa”	Haroldo Conti	Crónica
Prólogo a Operación Masacre	Rodolfo Walsh	Prólogo
“Martín Fierro” (fragmento)	José Hernández	Poesía
“Cosas de la vida” (en El país de humo)	Sara Gallardo	Cuento
“El sultán” (en La ola que lee)	César Aira	Crítica
Fragmentos de Cuentos secretos	Aurora Venturini	Cuento
“Kincón”	Miguel Briante	Cuento
Días de ocio en la Patagonia (fragmento)	William Hudson	Diario de viaje
Los diarios de Emilio Renzi. Años de formación (fragmento)	Ricardo Piglia	Diarios
“El galpón de la libido” (en Cerrá cuando te vayas)	Horacio Fiebelkorn	Aguafuerte
Fragmentos de La noche	Alberto Muñoz	Relato
Fragmentos de Glaxo	Hernán Ronsino	Novela
“René Lavand: mago de una sola mano” (en Frutos extraños)	Leila Guerriero	Crónica

Cuadro 1: Listado de lecturas

como en las respuestas generadas. Los costos varían según el modelo específico utilizado, siendo Claude 2.1 (desarrollado por Anthropic) y Llama 3 (Meta) algunos de los modelos disponibles a través de esta plataforma. Es importante destacar que el uso de estos servicios representa una inversión significativa en términos de recursos computacionales y financieros, factor que debe considerarse en la planificación e implementación de proyectos similares.

4. Desarrollo

4.1. DECUBO

Dada la problemática, se busca desarrollar un benchmark para evaluar sesgos culturales, lingüísticos y geográficos en Modelos de Lenguaje de Gran Escala (LLMs) cuando procesan textos literarios argentinos. A través del análisis de textos como “El mar, modo de uso” de Juan Forn y ”Polemistas”de Borges y Bioy, se construyó un conjunto de preguntas que exploran la capacidad de los modelos para comprender las múltiples capas de significado presentes en la literatura argentina. Este enfoque examina cinco dimensiones clave de sesgo que muchas veces se solapan entre si: geográfico-culturales (como la comprensión de las dinámicas entre provincias mediterráneas y la costa), lingüísticos (incluyendo modismos rioplatenses y referencias culturales cruzadas), socioculturales (abarcando códigos sociales y transformaciones culturales), comprensión contextual (evaluando el entendimiento de referencias históricas y subtextos) y conocimiento cultural (midiendo la interpretación de referencias literarias y prácticas sociales específicas). Este benchmark no solo busca evaluar la precisión en la comprensión literal del texto, sino también la capacidad de los modelos para captar matices culturales, referencias geográficas específicas y significados implícitos que son fundamentales para la correcta interpretación de la literatura argentina.

4.1.1. Enfoque multidimensional del análisis

La decisión de examinar cinco dimensiones de sesgo (geográfico-culturales, lingüísticos, socioculturales, comprensión contextual y conocimiento cultural) respondió a las características particulares del proceso de investigación. A diferencia de otros benchmarks que parten de la construcción de un corpus específicamente diseñado para evaluar un tipo concreto de sesgo, el punto de partida fue un conjunto de textos preexistente, seleccionado por la Dirección Provincial de Bibliotecas por su relevancia cultural y literaria para la región bonaerense.

Esta particularidad metodológica presentó tanto limitaciones como oportunidades. Por un lado, la necesidad de digitalizar los textos en colaboración con la biblioteca implicó una inversión significativa de recursos, lo que hacía poco eficiente descartar material por no ajustarse a una única dimensión de análisis. Por otro lado, al trabajar con un corpus literario rico en matices culturales pero no construido específicamente para la evaluación de sesgos, resultaba difícil extraer un número estadísticamente significativo de preguntas centradas en una única dimensión (por ejemplo, puramente lingüística o exclu-

sivamente geográfica).

La naturaleza multifacética del corpus condujo a la adopción de un marco analítico más comprehensivo, permitiendo un aprovechamiento integral de las diversas capas interpretativas presentes en los textos seleccionados. Este enfoque multidimensional, si bien presenta mayores desafíos metodológicos, permite una evaluación más precisa de cómo los diferentes tipos de sesgos se intersectan en la comprensión de textos culturalmente situados, reflejando la complejidad inherente a la interpretación de obras literarias que incorporan múltiples niveles de significación cultural, geográfica y lingüística.

4.2. Conformación del corpus de textos

En el marco de la investigación, se optó por delegar la selección del corpus de textos a la Dirección Provincial de Bibliotecas y Promoción de la Lectura. Esta dirección se enfoca en la gestión y promoción de la cultura y la lectura en la Provincia de Buenos Aires a través de múltiples iniciativas. Desde la Dirección, se propusieron un total de 21 textos 1 que incluyan elementos narrativos vinculados con las características de la región. Los textos corresponden a distintos géneros: ensayo, novela, aguafuerte, crónica, poesía, crítica, etc. La mayor parte de estos textos están marcados por un lenguaje literario.

4.3. Dataset de preguntas

Para tener un primer acercamiento acerca de cómo los modelos se aproximan a la comprensión de textos situados, se implementó un proceso de dos etapas para la generación del conjunto de preguntas. En la primera fase, se utilizó el modelo o1 de OpenAI para generar un banco inicial de preguntas, empleando un prompt estructurado que especificaba criterios rigurosos sobre la naturaleza de las preguntas. Este prompt fue diseñado para garantizar que las preguntas abordaran múltiples dimensiones de comprensión: desde el vocabulario local y modismos hasta referencias geográficas, históricas y culturales específicas de la región bonaerense. También fue útil para obtener información sobre qué características de los textos los LLMs ponen mayor atención para crear un dataset de preguntas y en base a esa información, producir cambios sobre las preguntas o hacer nuevas.

En una segunda fase, el personal especializado en textos bonaerenses de la Dirección Provincial de Bibliotecas y Promoción de la Lectura, realizó una depuración exhaustiva de las preguntas generadas. Durante este proceso, no solo se refinaron las preguntas existentes sino que también se incrementó su nivel de complejidad para asegurar una evaluación más rigurosa de la comprensión contextual y cultural de los modelos. Este enfoque híbrido permitió combinar la eficiencia de la generación automatizada con la experticia humana en la curaduría del contenido, resultando en un conjunto de preguntas que evalúa efectivamente la comprensión profunda de los textos en su contexto sociocultural específico. Si bien se trabajó con textos literarios, se buscó que cada pregunta tenga una respuesta inequívoca o claramente preponderante por sobre el resto.

Este es ejemplo de cómo se llevó a cabo este proceso de añadir complejidad a las preguntas

Sobre texto de Juan Forn - Generada por o1 de OpenAI

En el texto, ¿qué significa la expresión “Se la juego” utilizada por Cabrera?

a) Que acepta el desafío propuesto.
b) Que rechaza participar en el juego.
c) Que apuesta dinero en una partida de naipes.
d) Que amenaza con violencia a Albarracín.

Respuesta correcta: a)

Sobre texto de Juan Forn - Corregida

En el texto, ¿qué significa la expresión “Se la juego” utilizada por Cabrera?

a) Que acepta el desafío propuesto.
b) Que rechaza participar en el juego.
c) Que apuesta todo su dinero.
d) Que amenaza con violencia.

Respuesta correcta: a

El análisis de los distractores revela cómo las variaciones sutiles en las opciones de respuesta pueden explotar sesgos culturales y lingüísticos específicos. Por ejemplo, al eliminar la referencia a los ”naipes.[en] la opción c, la respuesta adquiere mayor plausibilidad sin llegar a ser correcta, ya que la expresión ”jugársela”podría interpretarse, en otros contextos geográficos o lingüísticos, como una apuesta monetaria debido a la presencia de un desafío en la narrativa. De manera similar, la opción d, al prescindir de la referencia específica a Albarracín, presenta la amenaza como una declaración general, lo cual podría resonar con interpretaciones estereotipadas sobre el comportamiento desafiante del gaucho. Estos distractores funcionan como indicadores efectivos de la capacidad del modelo para distinguir entre interpretaciones culturalmente situadas y lecturas descontextualizadas del texto.

Algunas preguntas generadas por el modelo, presentaron opciones y respuestas que no resultan del todo satisfactorias o que no captan el sentido del texto. Aquí hay un ejemplo en el que en lugar de destacar lo improbable -un policía bonaerense hablando en lenguaje inclusivo y utilizando la x en la oralidad-, se ofrece como respuesta correcta la adopción del lenguaje inclusivo en la sociedad contemporánea.

Sobre texto de Celeste Dieguez - Generada por o1 de OpenAI

¿Qué implica el uso de "Tranquilx" por parte del policía en el contexto sociocultural argentino?

a) Refleja la adopción de lenguaje inclusivo en la sociedad contemporánea.

b) Indica un error tipográfico sin relevancia en el diálogo.

c) Representa un dialecto antiguo de la región pampeana.

d) Muestra la falta de educación formal del policía.

Respuesta correcta: [a]

Justificación

El uso de "Tranquilx" con "x" es una forma de lenguaje inclusivo que busca neutralizar el género, reflejando cambios sociales y lingüísticos en Argentina.

Criterio Se optó por elegir aquellas preguntas que, además de tener características suficientes para evaluar alguna de las dimensiones claves de sesgo que se listaron anteriormente, resultaran significativas para el equipo de investigación. Otras preguntas, alrededor del 20 %, fueron redactadas desde 0 por el equipo de la Dirección dado que los modelos no habían sido satisfactorias.

Sobre la generación automática Si bien la generación automática presupone que un modelo puede responder correctamente a una pregunta generada por él mismo, o que otros modelos más ligeros puedan tener una aproximación similar, el fin de esta práctica fue tener una idea general de "quéçomprende el modelo, para luego modificar la pregunta con varios distractores. A pesar de los problemas que presentan los modelos para la generación de preguntas, estos hicieron un aporte significativo a la construcción de los datasets de preguntas: En principio, sirvieron para determinar si los modelos podían generar preguntas que resultaran significativas y tener una primera aproximación a los posibles sesgos.

4.4. Selección de modelos para evaluar

Se eligieron modelos que son de uso corriente en la región, preferentemente aquellos que son de acceso gratuito por una u otra vía.

Formato de las tablas Se replicó el modelo de CSV con el que se creó el benchmark MMLU [6]. Esto implica: una columna que incluya el texto y la consulta unidas; otras cuatro columnas para las opciones; una última columna para la respuesta correcta.

Test automático Se desarrolló un script en Python para automatizar la ingesta del CSV y la producción de un resultado a los múltiples tests. Link a GitHub

5. Resultados

5.1. Resultados preliminares

Tras el primer procesamiento por parte de los modelos, el dataset produjo algunos errores con la API de GPT-4, dado que el modelo se veía excedido por la cantidad de tokens. Por otro lado, el primer resultado sirvió para encontrar errores en el armado del dataset.

Cuadro 2: Análisis preliminar del Benchmark

model	responses	accuracy	answered
llama370b	68	91.18	68
gpt4	68	79.41	68
claude 2.1	68	72.06	68
mistral7b	68	70.59	68
llama38b	68	66.18	68

5.1.1. Imputación de datos y filtrado

Dado que este trabajo se realizó con un presupuesto de 20 dólares, se decidió imputar aquellas preguntas -un total de tres- mal cargadas en el dataset y considerarlas como bien respondidas, ya que tras algunas pruebas manuales con las preguntas corregidas obtuvimos todas respuestas correctas. También se decidió no contabilizar aquellas preguntas en las que GPT-4 viera su límite excedido, afectando su tasa porcentual.

5.2. Resultados Finales

Como puede verse en el Cuadro 3, el rendimiento de GPT4 y Llama 3 70b se posiciona en lo más alto, sobrepasando el 90 % de exactitud en ambos casos. Destaca también la baja correlación de errores de GPT4 con otros modelos, aunque hay que tener en cuenta que tiene menos respuestas contabilizadas.

Cuadro 3: Métricas Ajustadas (Excluyendo Errores de Tokens)

model	total	accuracy	questions
gpt4	58	93.10	58
llama370b	68	91.18	68
claude 2.1	68	72.06	68
mistral7b	68	70.59	68
llama38b	68	66.18	68

Comparación de GPT-4:
Accuracy Original: 79.41 %
Accuracy Ajustada: 93.10 %

Número de casos con error de tokens: 10

Cuadro 4: Correlación de Errores entre Modelos

model	claude	gpt4	llama370b	llama38b	mistral7
claude	1.00	0.09	0.27	0.25	0.32
gpt4	0.09	1.00	0.10	0.10	0.07
llama370b	0.27	0.10	1.00	0.11	-0.09
llama38b	0.25	0.10	0.11	1.00	0.29
mistral7b	0.32	0.07	-0.09	0.29	1.00

5.3. Niveles de dificultad

Para establecer una clasificación objetiva de la dificultad de las preguntas, se implementó un sistema basado en el rendimiento general observado en los datos **??**. La metodología se fundamenta en el porcentaje de respuestas correctas obtenidas para cada pregunta, estableciendo cuatro niveles distintos: preguntas fáciles (mayor a 80 % de tasa de acierto), dificultad media (entre 50 % y 80 %), difíciles (entre 20 % y 50 %) y muy difíciles (menor a 20 %). La implementación de esta clasificación se realizó mediante un análisis computacional que calcula el porcentaje general de respuestas correctas para cada pregunta y las categoriza según los umbrales establecidos.

5.3.1. Cantidad de habitantes

Sobre texto de Los Peligrosos Gorriones

Si bien nunca se nombra, el pogo durante el concierto de los Peligrosos Gorriones congrega a unas treinta personas en una ciudad de 600 mil. ¿Qué lugar podría ser?

a) Chivilcoy
b) Tres Arroyos
c) Mar del Plata
d) La Plata

Respuesta correcta: c

La respuesta correcta es Mar del Plata, ciudad natal del escritor Martín Zariello. Aunque La Plata aparece como un distractor convincente por ser la ciudad de origen de la banda Peligrosos Gorriones, un dato clave confirma que no es la respuesta correcta:

Demografía La Plata tiene 772.618 habitantes según el último censo, mientras que Mar del Plata cuenta con 667.082, teniendo 593.337 en la fecha en que fue escrita la crónica.

En cuanto a las respuestas de los modelos de IA:

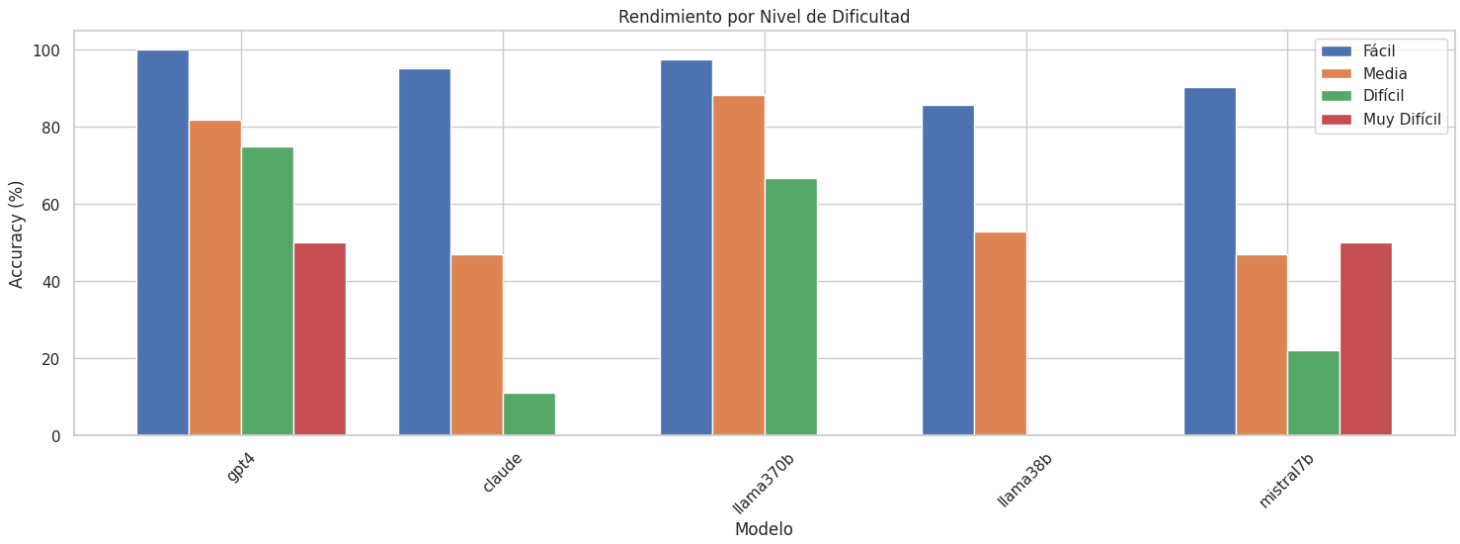
- GPT-4 y Llama 3 80b respondieron: La Plata
- Mistral respondió: Mar del Plata (correcta)
- Los demás modelos respondieron: Chivilcoy

Investigación posterior En algunas iteraciones con Claude Sonnet 3.5, se pudo corroborar como el modelo de lenguaje tiende a confundir Mar del Plata y La Plata como ciudad de origen de Peligrosos Gorriones. Si bien responde por default "La Plata"frente a cualquier pregunta, la sola mención de Mar del Plata en un prompt hace que el modelo no pueda evitar la confusión. Ante una pregunta como la siguiente, el modelo automáticamente vincula a la banda con Mar del Plata: Estoy en Mar del Plata. ¿Te gusta Peligrosos Gorriones?

Mar del Plata Otra pregunta que tuvo dificultad y que pudo ser respondida correctamente sólo por GPT-4 es "¿sobre qué río se sitúa Patagones?". El título del cuento de Roberto Arlt es "La tragedia de un padre que va a Mar del Plata", repite Mar del Plata y 3/5 modelos coinciden en que la respuesta correcta es "Río de La Plata", siendo que la respuesta correcta es "Río Negro".



Figura 1: El Río Negro separando Carmen de Patagones de Viedma



5.4. Otros casos

Sobre texto "Polemistas" de Borges & Bioy

"Varios gauchos en la pulpería conversan sobre temas de escritura y de fonética. El santiagueño Albarracín no sabe leer ni escribir, pero supone que la palabra trara no puede escribirse. Crisanto Cabrera, también analfabeto, sostiene que todo lo que se habla puede ser escrito. —Pago la copa para todos —le dice el santiagueño— si escribe trara. —Se la juego —contesta Cabrera; saca el cuchillo y con la punta traza unos garabatos en el piso de tierra. De atrás se asoma el viejo Álvarez, mira el suelo y sentencia: —Clarito, trara."
Teniendo en cuenta el contexto histórico-cultural, ¿qué se puede inferir sobre el personaje del viejo Álvarez cuando dice: "Clarito, trara"?

a) Que sabe leer y confirma que está bien escrito.
b) Que apoya a Cabrera y valida su esfuerzo.
c) Que está confundido y no entiende la situación.
d) Que, aunque es tan analfabeto como los otros, simula una comprensión.

Respuesta correcta: d

El texto en cuestión constituye una pieza narrativa que forma parte del corpus antológico Cuentos breves y extraordinarios, obra compilatoria publicada en 1955 bajo la curaduría editorial de Jorge Luis Borges y Adolfo Bioy Casares. Los editores atribuyen la autoría del relato a Luis L. Antuñano, quien presuntamente lo habría incluido en su obra Cincuenta años en Gorchs. Medio siglo en campos de Buenos Aires, texto que, según las referencias proporcionadas, fue publicado en la localidad bonaerense de Olavarría en 1911.

Cabe señalar que la atribución de la fuente merece un análisis crítico, considerando la reconocida práctica borgiana y bioycasariana de construir complejos sistemas de referencias bibliográficas que oscilan entre lo factual y lo ficcional, procedimiento que forma parte integral de su poética y que problematiza deliberadamente los límites entre la realidad histórica y la construcción literaria.

Tanto Claude 2.1 como Llama 3 80b respondieron incorrectamente, con la respuesta "a". Este caso de multiple choice, es muy representativo de los textos literarios en los que la interpretación del lector cumple un rol fundamental en el armado del sentido. Pero entendiendo no solamente el contexto, sino el humor de los compiladores (o escritores), la respuesta "d" es la más probable de todas.

6. Conclusiones

El benchmark DECUBO ha demostrado ser una herramienta valiosa para evaluar la capacidad de los LLMs en la comprensión de textos literarios culturalmente situados en la provincia de Buenos Aires. Los resultados revelan una clara estratificación en el rendimiento de los modelos, con GPT-4 y Llama 3 70B alcanzando niveles notablemente superiores (más de 90 %) en comparación con modelos más pequeños (menos de 73 %).

La baja correlación de errores entre modelos sugiere que cada uno presenta debilidades diferentes en la comprensión cultural y contextual, lo que indica la necesidad de diversificar las estrategias de evaluación en futuros benchmarks. Los casos de estudio analizados, particularmente en referencias geográficas y culturales específicas, revelan que incluso los modelos más avanzados pueden mostrar inconsistencias en la interpretación de contextos locales.

Las limitaciones del estudio, incluyendo las restricciones presupuestarias y el tamaño del corpus, sugieren la necesidad de ampliar la investigación con un conjunto más extenso de textos y preguntas. Sin embargo, la metodología desarrollada proporciona un marco replicable para la evaluación de sesgos culturales en LLMs. Resultaría valioso examinar cómo estas limitaciones de comprensión cultural podrían impactar en aplicaciones prácticas de los LLMs en contextos educativos y profesionales de distintas regiones, no solamente del territorio bonaerense, sino también de territorios más postergados.

Agradecimientos

Agradecemos principalmente a la Dirección de Bibliotecas y Promoción de la Lectura, bajo la órbita de Ximena Talento por el trabajo realizado. A Martín E. Graziano que aportó todo su conocimiento enciclopédico sobre escritores de la provincia para armar este corpus, estando detrás de cada pregunta formulada a los modelos. A Oscar Jalil. A Palmira.

Referencias

[1] Shervin Minaee, Tomas Mikolov, Narjes Nikzad, Meysam Chenaghlu, Richard Socher, Xavier Amatriain, and Jianfeng Gao. Large language models: A survey, 2024.

[2] Viet Lai, Nghia Ngo, Amir Pouran Ben Veyseh, Hieu Man, Franck Dernoncourt, Trung Bui, and Thien Nguyen. ChatGPT beyond English: Towards a comprehensive evaluation of large language models in multilingual learning. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 13171–13189, Singapore, December 2023. Association for Computational Linguistics.

[3] Irene Plaza, Nina Melero, Cristina del Pozo, Javier Conde, Pedro Reviriego, Marina Mayor-Rocher, and María Grandury. Spanish and llm benchmarks: is mmlu lost in translation?, 2024.

[4] La Nación. Chatgpt tiene 200 millones de usuarios y un lugar muy especial para la argentina. https://www.lanacion.com.ar/tecnologia/chatgpt-tiene-200-millones-de-usuarios-y-un- lugar-muy-especial-para-la-argentina-nid30082024, 2024. [Accessed 06-11-2024].

[5] OpenAI et al. Gpt-4 technical report, 2024.

[6] Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. Measuring massive multitask language understanding, 2021.

[7] Wei Zhao, Steffen Eger, Johannes Bjerva, and Isabelle Augenstein. Inducing language-agnostic multilingual representations, 2021.

[8] Siqi Shen, Lajanugen Logeswaran, Moontae Lee, Honglak Lee, Soujanya Poria, and Rada Mihalcea. Understanding the capabilities and limitations of large language models for cultural commonsense, 2024.

[9] Boyang Xue, Hongru Wang, Rui Wang, Sheng Wang, Zezhong Wang, Yiming Du, Bin Liang, and Kam-Fai Wong. Mlingconf: A comprehensive study of multilingual confidence estimation on large language models, 10 2024.

[10] Maximiliano Linares. Hernán ronsino, por una literatura humana. notas sobre un escritor necesario. *Landa*, 12 2019.

[11] Unam - conocimientos fundamentales de literatura. http://conocimientosfundamentales.rua.unam.mx/literatura/Text/12_tema_01_1.1.7.html#:~:text=El%20car%C3%A1cter%20ambiguo%20o%20polis%C3%A9mico,interpretaciones%20de%20una%20misma%20obra.